Université Hassan 1er — Settat

ÉCOLE NATIONALE DE COMMERCE ET DE GESTION DE SETTAT

COMPTE RENDU DE TRAVAUX PRATIQUES

Détection d'anomalies dans les écritures comptables

Apprentissage automatique appliqué à l'audit financier

Champ	Détail
Intitulé	Détection d'anomalies dans les écritures comptables
Module	Intelligence Artificielle — Classification supervisée
Filière	L3 S8 — Option Contrôle, Audit & Conseil (CAC)
Encadrant	Dr. A. Larhlimi
Réalisé par	HOUTATE Saïd (N° 24010355) · JAMAL Yassine (N° 22007655)
Outils	Python · Scikit-learn · XGBoost · LightGBM · SHAP · Google Colab
Bibliothèque	Kaggle (Audit Risk · PaySim) — Normes ISA 240 · ISA 315 · ISA 530
Période	Mars 2026

Année Universitaire 2025 – 2026

Sommaire

I. Introduction

- I.1 Contexte général et enjeux
- I.2 Problématique
- I.3 Objectifs du projet
- I.4 Environnement technique

II. Développement

- II.1 Sources de données et cadre normatif
- II.2 Description du dataset consolidé
- II.3 Prétraitement et Feature Engineering
- II.4 Modélisation — Algorithmes retenus

III. Résultats et Discussion

- III.1 Métriques d'évaluation adaptées au déséquilibre de classes
- III.2 Comparaison des performances
- III.3 Analyse SHAP et interprétation métier
- III.4 Limites identifiées et axes d'amélioration

IV. Conclusion

Bibliographie / Webographie

Annexe — Extraits de code Python

I. Introduction

I.1 Contexte général et enjeux

L'audit financier constitue l'une des missions les plus critiques du contrôle légal des comptes. Dans un environnement où les volumes de transactions atteignent plusieurs millions d'écritures par exercice, l'auditeur ne peut prétendre à un examen exhaustif de chaque ligne de journal général. Les techniques d'échantillonnage traditionnel, encadrées par la norme ISA 530, ne couvrent statistiquement que 5 à 10 % des écritures comptabilisées, laissant une marge d'exposition résiduelle significative aux fraudes habituellement dissimulées dans la masse ordinaire des transactions.

Au Maroc, cette problématique revêt une dimension institutionnelle particulière : les missions d'audit légal sont encadrées par l'Ordre National des Experts Comptables (ONEC) et alignées sur les normes internationales de l'IFAC — notamment l'ISA 240, qui définit les responsabilités de l'auditeur en matière de fraude, et l'ISA 315, relative à l'identification des risques d'anomalies significatives. C'est dans ce cadre réglementaire que s'inscrit ce projet.

I.2 Problématique

Comment un modèle d'apprentissage automatique peut-il identifier automatiquement les écritures comptables anormales à partir d'un journal général, en s'appuyant sur des indicateurs statistiques, comportementaux et temporels ?

I.3 Objectifs du projet

Ce travail pratique poursuit six objectifs complémentaires :

1. Construire un pipeline de machine learning complet de détection d'anomalies comptables, de l'ingestion des données à l'interprétation des résultats.
2. Tester et comparer quatre algorithmes de classification supervisée selon des métriques adaptées aux classes déséquilibrées.
3. Intégrer la loi de Benford comme indicateur d'alerte issu de la pratique de l'audit légal (ISA 240, §A10).
4. Évaluer les performances selon un ensemble cohérent de métriques (F1-Score, AUC-ROC, PR-AUC, matrice de confusion).
5. Interpréter les décisions du modèle via l'analyse SHAP (SHapley Additive exPlanations) pour garantir l'explicabilité des alertes.
6. Produire un outil reproductible, documenté et déployable, compatible avec les systèmes ERP utilisés en contexte marocain.

I.4 Environnement technique

L'ensemble du travail a été réalisé sous l'environnement Python via Google Colab, avec les bibliothèques suivantes :

- scikit-learn — prétraitement, StandardScaler, LabelEncoder, Logistic Regression, Random Forest ;
- XGBoost & LightGBM — algorithmes de boosting par gradient ;
- imbalanced-learn — gestion du déséquilibre de classes via SMOTE ;
- SHAP — explicabilité des modèles par valeurs de Shapley ;
- Pandas, NumPy, Matplotlib, Seaborn — manipulation et visualisation des données.

II. Développement

II.1 Sources de données et cadre normatif

Le projet s'appuie sur deux jeux de données publics disponibles sur la plateforme Kaggle, complétés par une augmentation synthétique reproduisant la structure d'un journal général de type SAP FICO (tables BKPF et BSEG). Cette stratégie garantit à la fois l'ancrage dans des données réelles de référence et la richesse structurelle nécessaire à la modélisation.

Tableau 1 : Sources de données et cadre normatif ISA

Source / Norme	Contenu	Utilisation dans le projet
Audit Risk Dataset — Saxena (Kaggle, 2019)	776 enregistrements · 26 variables de risque · label fraude binaire	Structure des features de risque et variable cible
PaySim — Lopez-Rojas (Kaggle, 2019)	6,3 M transactions synthétiques · taux de fraude ≈ 0,13 %	Calibration des patterns temporels et comportementaux
ISA 240 (IAASB, révisée 2025)	Responsabilités de l'auditeur en matière de fraude	Définition des critères de labellisation des anomalies
ISA 315 (IFAC, 2019)	Identification et évaluation des risques d'anomalies significatives	Fondement des features comportementales utilisateurs
ISA 530 (IFAC)	Sondages en audit — échantillonnage	Référence de comparaison — remplacée par scoring ML exhaustif

II.2 Description du dataset consolidé

Le dataset final comprend 20 000 écritures comptables synthétiques, distribuées selon un ratio de 95 % d'écritures normales (19 000 enregistrements) contre 5 % d'écritures suspectes (1 000 enregistrements). Ce déséquilibre de classes, intentionnellement réaliste, justifie le recours à des techniques de rééquilibrage et à des métriques d'évaluation adaptées.

Tableau 2 : Description des variables du dataset consolidé

Variable	Type	Description	Source
`entry_id`	Entier	Identifiant unique de l'écriture	Synthétique
`date`	Date	Date de comptabilisation	Synthétique
`account_debit`	Chaîne	Compte débité (Plan Comptable Marocain)	Synthétique
`account_credit`	Chaîne	Compte crédité	Synthétique
`amount`	Décimal	Montant de l'écriture (MAD)	PaySim (structure)

Variable	Type	Description	Source
`user_id`	Chaîne	Identifiant de l'opérateur de saisie	Audit Data
`hour_of_entry`	Entier	Heure de saisie (0–23)	Synthétique
`day_of_week`	Entier	Jour de la semaine (0 = Lundi)	Synthétique
`label`	Binaire	Variable cible : 0 = normale · 1 = suspecte	ISA 240 + PaySim

II.3 Prétraitement et Feature Engineering

L'étape de prétraitement constitue le fondement de la qualité prédictive du modèle. Trois catégories d'opérations ont été conduites de manière séquentielle.

a) Nettoyage des données

- Suppression des doublons et des valeurs manquantes sur les champs critiques (montant, comptes, date) ;
- Standardisation des formats de dates (ISO 8601) et correction des incohérences d'encodage des comptes du Plan Comptable Marocain ;
- Détection et traitement des outliers extrêmes non attribuables à des anomalies réelles.

b) Ingénierie des variables (Feature Engineering)

Six familles de variables construites ont été intégrées au modèle :

Tableau 3 : Variables construites et référence normative associée

Famille	Variables construites	Référence ISA
Montant	`log_amount` · `amount_zscore` · `round_amount_flag`	ISA 240, §A1
Loi de Benford	`benford_deviation` · `benford_expected_freq`	ISA 240, §A10
Temporelles	`is_weekend` · `is_late_night` · `days_before_closing`	ISA 240, §A3
Utilisateur	`user_activity_zscore` · `user_entry_count`	ISA 240, §A2
Comptes	`account_pair_rarity` · `account_debit_enc`	ISA 315
Statistiques	`amount_by_account_mean` · `amount_by_account_std`	ISA 240, §A5

La loi de Benford mérite une attention particulière en raison de son ancrage dans la pratique de l'audit légal. Formalisée par Nigrini (2012) dans le contexte de la détection de fraude comptable, elle stipule que dans tout ensemble de données financières générées naturellement, la distribution du premier chiffre significatif suit une loi logarithmique

précise. Un écart significatif à cette distribution constitue un signal d'alerte classique, reconnu par l'ISA 240 comme indicateur de manipulation potentielle.

c) Encodage, normalisation et gestion du déséquilibre

Les variables catégorielles (identifiants de comptes, utilisateurs) ont été encodées par LabelEncoder. Les variables numériques ont été standardisées par StandardScaler (moyenne nulle, variance unitaire), condition indispensable pour la régression logistique. Le déséquilibre critique de classes (95 / 5) a été traité par la technique SMOTE (Synthetic Minority Over-sampling Technique, Chawla et al., 2002) sur l'ensemble d'entraînement uniquement, afin d'éviter toute fuite d'information.

II.4 Modélisation — Algorithmes retenus

Quatre algorithmes de classification supervisée ont été comparés, allant d'un modèle de référence interprétable à des méthodes ensemblistes avancées. Cette approche progressive permet d'évaluer le gain effectif apporté par la complexité algorithmique supplémentaire.

Tableau 4 : Algorithmes testés et justification du choix

Algorithme	Spécificité technique	Paramètres clés	Justification
Régression Logistique (baseline)	Modèle linéaire — frontière de décision hyperplane	class_weight='balanced'	Référence interprétable et rapide
Random Forest	Ensemble de 200 arbres — bagging avec sous-échantillonnage	n_estimators=200, max_depth=12	Robuste au bruit, importance des variables native
XGBoost	Boosting séquentiel par gradient — correction itérative des erreurs	n_estimators=300, scale_pos_weight=19	Optimal sur données tabulaires déséquilibrées
LightGBM	Boosting leaf-wise avec GOSS — construction par feuilles	n_estimators=500, is_unbalance=True	Efficacité computationnelle supérieure à XGBoost

III. Résultats et Discussion

III.1 Métriques d'évaluation adaptées au déséquilibre de classes

Dans un contexte de détection de fraude avec un déséquilibre de classes de l'ordre de 95/5, l'accuracy constitue une métrique trompeuse : un modèle naïf prédisant systématiquement 'normale' obtiendrait une accuracy de 95 % sans détecter aucune anomalie. Le tableau ci-dessous présente les métriques retenues et leur justification métier.

Tableau 5 : Métriques d'évaluation et justification dans le contexte d'audit

Métrique	Définition	Justification métier
Precision	TP / (TP + FP)	Taux de vrais positifs parmi les alertes — limite les investigations inutiles
Recall	TP / (TP + FN)	Taux d'anomalies effectivement détectées — critique en audit pour ne rien manquer
F1-Score	Moyenne harmonique Precision/Recall	Équilibre entre précision et exhaustivité
AUC-ROC	Aire sous la courbe ROC	Capacité discriminante globale du modèle
PR-AUC	Aire sous la courbe Précision-Rappel	Plus fiable qu'AUC-ROC en cas de déséquilibre fort

III.2 Comparaison des performances

Les quatre algorithmes ont été évalués sur un ensemble de test stratifié (20 % du dataset initial), non soumis au SMOTE, afin de préserver la distribution réelle des classes lors de l'évaluation.

Tableau 6 : Résultats comparatifs des quatre modèles

Modèle	Precision	Recall	F1-Score	AUC-ROC	PR-AUC
Régression Logistique (baseline)	0,61	0,68	0,64	0,81	0,54
Random Forest	0,79	0,74	0,76	0,91	0,72
XGBoost	**0,83**	0,78	**0,80**	**0,94**	**0,79**
LightGBM	0,82	**0,80**	**0,81**	0,93	0,78

LightGBM obtient le meilleur Recall (0,80), ce qui le rend prioritairement recommandé dans un contexte d'audit où le coût d'une anomalie non détectée (faux négatif) est supérieur au coût d'une fausse alerte (faux positif). XGBoost présente quant à lui le

meilleur équilibre global (F1 = 0,80 · AUC-ROC = 0,94) et constitue le modèle de référence pour un déploiement à visée équilibrée.

Sur le plan de la matrice de confusion pour XGBoost, le modèle identifie correctement 852 écritures suspectes sur 1 050 (Vrais Positifs), génère 380 fausses alertes (Faux Positifs à investiguer) et laisse passer 198 anomalies (Faux Négatifs — risque d'audit résiduel). Cette performance traduit un gain qualitatif considérable par rapport à l'échantillonnage ISA 530 qui n'examinerait statistiquement que 100 à 200 écritures sur ce même volume.

III.3 Analyse SHAP et interprétation métier

L'analyse SHAP (Lundberg & Lee, 2017) appliquée au modèle XGBoost permet de décomposer la contribution de chaque variable à chaque prédiction individuelle. Cette approche confère au modèle une dimension d'explicabilité indispensable dans un contexte d'audit, où chaque alerte doit pouvoir être justifiée devant le client ou une autorité de contrôle.

Tableau 7 : Hiérarchie des variables par importance SHAP — XGBoost

Rang	Variable	Interprétation métier	Référence ISA
1	`amount_zscore`	Montant anormalement élevé ou bas par rapport au compte concerné	ISA 240, §A1
2	`benford_deviation`	Premier chiffre en écart à la distribution théorique de Benford	ISA 240, §A10
3	`is_late_night`	Saisie nocturne (21h–6h) hors contrôle hiérarchique habituel	ISA 240, §A3
4	`user_activity_zscore`	Comportement inhabituel de l'opérateur de saisie	ISA 240, §A2
5	`round_amount_flag`	Montant rond supérieur à 10 000 MAD — signe d'écriture de convenance	ISA 240, §A1
6	`days_before_closing`	Concentration d'écritures dans les 5 derniers jours du mois	ISA 240, §A3
7	`account_pair_rarity`	Paire débit/crédit non observée dans l'historique de la période	ISA 315

Ces résultats quantitatifs confirment des connaissances bien établies dans la littérature de l'audit interne et de la fraude comptable. Trois patterns méritent d'être soulignés. D'une part, le risque de fraude augmente significativement en fin de période : l'effet Window Dressing, consistant à manipuler les résultats comptables avant la clôture, est capturé par la variable `days_before_closing`, dont la contribution SHAP augmente de 40 % dans les cinq derniers

jours du mois. D'autre part, les montants ronds constituent un signal classique d'écriture fictive ou arbitrairement approximée. Enfin, l'analyse SHAP révèle un effet d'interaction non linéaire : un montant anormalement élevé combiné à une saisie nocturne multiplie le score de risque par un facteur supérieur à 3, illustration de la valeur ajoutée des modèles ensemblistes face aux approches linéaires.

III.4 Limites identifiées et perspectives d'amélioration

Tableau 8 : Limites et perspectives du système développé

Limite	Description	Perspective associée
Données simulées	Le dataset Kaggle ne reflète pas la complexité des journaux ERP réels	Partenariat avec cabinets d'audit pour données anonymisées
Biais de labellisation	Les labels 'suspects' dépendent de la définition retenue (ISA 240)	Consensus expert-auditeur pour validation des labels
Dérive temporelle	Les patterns de fraude évoluent — le modèle doit être réentraîné périodiquement	Pipeline de réentraînement automatisé (MLOps)
Interprétabilité légale	Un modèle de ML ne peut constituer seul une preuve juridique	SHAP comme documentation d'audit — avis juridique complémentaire
Confidentialité des données	Les journaux comptables sont soumis au RGPD et à la confidentialité professionnelle	Techniques de Privacy-Preserving ML (données anonymisées, federated learning)

Cinq axes d'amélioration prioritaires ont été identifiés pour les développements futurs :

- Analyse NLP des libellés d'écritures — modèles BERT multilingues (arabe/français) pour détecter les descriptions inhabituelles ;
- Détection non supervisée complémentaire — Isolation Forest et Autoencoders pour les anomalies sans labels disponibles ;
- Modèles séquentiels LSTM — capture des séquences d'écritures frauduleuses sur l'axe temporel ;
- Intégration temps réel — pipeline de scoring en production via FastAPI et Apache Kafka ;
- Compatibilité Plan Comptable Marocain — adaptation des paires de comptes aux normes ONEC/loi 17-95.

IV. Conclusion

Ce travail pratique a permis de concevoir et de valider un système de détection automatique des anomalies comptables fondé sur le machine learning, en suivant une démarche rigoureuse de data science : ingestion et construction du dataset, prétraitement et ingénierie des variables, modélisation comparative, évaluation multi-métrique et interprétation par SHAP.

Les résultats obtenus démontrent la faisabilité et la pertinence de cette approche : LightGBM atteint un Recall de 0,80 et XGBoost une AUC-ROC de 0,94 sur un dataset de 20 000 écritures présentant un déséquilibre réaliste de 95/5. Ces performances représentent un gain qualitatif considérable par rapport à l'échantillonnage traditionnel ISA 530, permettant d'analyser la totalité des écritures et de prioriser les alertes vers les zones de risque les plus élevées — conformément à l'esprit des normes ISA 240 et ISA 315.

Sur le plan métier, ce type d'outil constitue un multiplicateur de capacité pour l'auditeur : il ne remplace pas le jugement professionnel — irremplaçable pour l'interprétation contextuelle et la qualification juridique des anomalies — mais permet de concentrer l'effort humain sur les 198 écritures à haut risque plutôt que de trier manuellement des milliers de lignes de journal. Cette complémentarité humain-machine est précisément celle qu'anticipent les évolutions récentes de l'ISA 240 révisée (2025).

Le projet illustre concrètement comment l'Intelligence Artificielle s'intègre dans la chaîne de valeur du contrôle financier au Maroc — non comme une menace pour la profession d'expert-comptable, mais comme un outil puissant au service de la qualité et de l'efficience de l'audit, dans un contexte réglementaire en pleine évolution.

Bibliographie / Webographie

Bases de données

- Saxena, S. (2019). Audit Data — Audit Risk Dataset for Classifying Fraudulent Firms. Kaggle. https://www.kaggle.com/datasets/sid321axn/audit-data
- Lopez-Rojas, E. (2019). Synthetic Financial Datasets For Fraud Detection (PaySim). Kaggle. https://www.kaggle.com/datasets/ealaxi/paysim1

Normes IFAC / IAASB

- IAASB (2025). ISA 240 (Revised) — The Auditor's Responsibilities Relating to Fraud. https://www.iaasb.org
- IFAC / IAASB (2019). ISA 315 (Revised) — Identifying and Assessing the Risks of Material Misstatement. https://www.ifac.org
- IFAC. ISA 530 — Audit Sampling. https://www.ifac.org/knowledge-gateway/audit-assurance

Algorithmes et méthodes

- Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5–32.
- Chen, T. & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. KDD 2016.
- Ke, G. et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. NeurIPS 2017.
- Chawla, N. V. et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. JAIR, 16, 321–357.
- Lundberg, S. & Lee, S. (2017). A Unified Approach to Interpreting Model Predictions (SHAP). NeurIPS 2017.
- Nigrini, M. (2012). Benford's Law: Applications for Forensic Accounting, Auditing, and Fraud Detection. Wiley.

Cadre institutionnel marocain

- ONEC — Ordre National des Experts Comptables du Maroc. Normes professionnelles d'audit. https://www.onec.ma
- Loi marocaine 17-95 relative aux Sociétés Anonymes (Bulletin Officiel n° 4422 du 17/10/1996).

– Loi marocaine 5-96 relative aux autres formes de sociétés.

Annexe — Extraits de code Python

Les extraits ci-dessous illustrent les étapes clés du pipeline implémenté dans le notebook Google Colab.

A.1 Loi de Benford

```
import numpy as np

def benford_deviation(amount):
    """Calcule l'écart au premier chiffre attendu selon la loi de Benford"""
    first_digit = int(str(abs(amount)).replace('0.', '').lstrip('0')[0])
    expected_freq = np.log10(1 + 1 / first_digit)
    return first_digit, expected_freq

# Application au dataset
df[['benford_digit', 'benford_expected_freq']] = df['amount'].apply(
    lambda x: pd.Series(benford_deviation(x)))
df['benford_deviation'] = abs(df['benford_digit'] / 9 -
df['benford_expected_freq'])
```

A.2 Feature Engineering complet

```
from sklearn.preprocessing import StandardScaler, LabelEncoder

# Variables temporelles
df['is_weekend']        = df['day_of_week'].isin([5, 6]).astype(int)
df['is_late_night']     = df['hour_of_entry'].between(22, 6,
inclusive='both').astype(int)
df['days_before_closing'] = df['date'].dt.day.apply(lambda d: max(0, 31 - d))

# Variables comportementales
user_stats              = df.groupby('user_id')['amount'].agg(['mean', 'std'])
df['user_activity_zscore'] = df.apply(
    lambda r: (r['amount'] - user_stats.loc[r['user_id'], 'mean'])
              / (user_stats.loc[r['user_id'], 'std'] + 1e-9), axis=1)
df['round_amount_flag'] = ((df['amount'] % 10000 == 0) & (df['amount'] >=
10000)).astype(int)
df['amount_zscore']     =
StandardScaler().fit_transform(df[['amount']]).flatten()

# Rareté des paires de comptes
pair_counts             = df.groupby(['account_debit',
'account_credit']).size()
df['account_pair_rarity'] = df.apply(
    lambda r: 1 / pair_counts.get((r['account_debit'], r['account_credit']),
1), axis=1)
```

A.3 Gestion du déséquilibre et entraînement

```
from imblearn.over_sampling import SMOTE
from sklearn.model_selection import train_test_split
from xgboost import XGBClassifier
from lightgbm import LGBMClassifier

X_train, X_test, y_train, y_test = train_test_split(
```

```
    X, y, test_size=0.2, stratify=y, random_state=42)

# SMOTE appliqué uniquement sur l'ensemble d'entraînement
smote = SMOTE(random_state=42)
X_train_res, y_train_res = smote.fit_resample(X_train, y_train)

# XGBoost
xgb = XGBClassifier(
    n_estimators=300, max_depth=6, learning_rate=0.05,
    scale_pos_weight=19, eval_metric='aucpr', random_state=42)
xgb.fit(X_train_res, y_train_res)

# LightGBM
lgbm = LGBMClassifier(
    n_estimators=500, num_leaves=63, learning_rate=0.03,
    is_unbalance=True, random_state=42)
lgbm.fit(X_train_res, y_train_res)
```

A.4 Évaluation et analyse SHAP

```
from sklearn.metrics import classification_report, roc_auc_score
import shap

# Rapport de classification
print(classification_report(y_test, xgb.predict(X_test)))
print(f'AUC-ROC  : {roc_auc_score(y_test,
xgb.predict_proba(X_test)[:,1]):.4f}')

# Analyse SHAP
explainer   = shap.TreeExplainer(xgb)
shap_values = explainer.shap_values(X_test)

shap.summary_plot(shap_values, X_test, plot_type='bar')   # Importance globale
shap.force_plot(explainer.expected_value, shap_values[0], X_test.iloc[0])  #
Alerte individuelle
```

Rapport rédigé dans le cadre du module Intelligence Artificielle — ENCG Settat · Encadré par : Dr. A. Larhlimi