École Nationale de Commerce et de Gestion
Université Hassan 1er — Settat, Maroc
Filière : **Contrôle, Audit & Conseil** Groupe : **CAC 2**
Module : **Intelligence Artificielle** Encadrant : **Dr. A. Larhlimi**

Compte Rendu de Travaux Pratiques

Détection d'anomalies dans les écritures comptables

Apprentissage automatique appliqué à l'audit financier

Champ	Détail
Intitulé	Détection d'anomalies dans les écritures comptables
Module	Intelligence Artificielle — Classification supervisée
Filière	Option Contrôle, Audit & Conseil (CAC)
Groupe	**CAC 2**
Encadrant	Dr. A. Larhlimi
Réalisé par	HOUTATE Saïd (N° Apogée : 24010355) • JAMAL Yassine (N° Apogée : 22007655)
Outils	Python · Scikit-learn · XGBoost · LightGBM · SHAP · Google Colab
Bibliothèque	Kaggle (Audit Risk · PaySim) — Normes ISA 240 · ISA 315 · ISA 530
Période	Mars 2026
Année Univ.	2025 – 2026

Équipe Projet

Détection d'anomalies comptables par Machine Learning

HOUTATE Saïd

N° Apogée : **24010355**
Filière : Contrôle, Audit & Conseil
Groupe : **CAC 2**
Université : ENCG Settat

JAMAL Yassine

N° Apogée : **22007655**
Filière : Contrôle, Audit & Conseil
Groupe : **CAC 2**
Université : ENCG Settat

Encadrant : Dr. A. Larhlimi
Module : Intelligence Artificielle — ENCG Settat
Année Universitaire : 2025 – 2026

Contents

1 Introduction **3**
1.1 Contexte général et enjeux . . . 3
1.2 Problématique . . . 3
1.3 Objectifs du projet . . . 3
1.4 Environnement technique . . . 3

2 Développement **5**
2.1 Sources de données et cadre normatif . . . 5
2.2 Description du dataset consolidé . . . 5
2.3 Prétraitement et Feature Engineering . . . 6
2.3.1 Nettoyage des données . . . 6
2.3.2 Ingénierie des variables (Feature Engineering) . . . 7
2.3.3 Encodage, normalisation et gestion du déséquilibre . . . 8
2.4 Modélisation — Algorithmes retenus . . . 10

3 Résultats et Discussion **12**
3.1 Métriques d'évaluation adaptées au déséquilibre de classes . . . 12
3.2 Comparaison des performances . . . 12
3.2.1 Matrices de confusion et courbes ROC par modèle . . . 13
3.3 Analyse SHAP et interprétation métier . . . 13
3.3.1 Interprétation métier . . . 16
3.4 Limites identifiées et axes d'amélioration . . . 17

4 Conclusion **18**

Bibliographie / Webographie **19**

A Extraits de code Python complémentaires **20**
A.1 Génération du dataset synthétique . . . 20
A.2 Analyse SHAP — Force Plot individuel . . . 20

1 Introduction

1.1 Contexte général et enjeux

L'audit financier constitue l'une des missions les plus critiques du contrôle légal des comptes. Dans un environnement où les volumes de transactions atteignent plusieurs millions d'écritures par exercice, l'auditeur ne peut prétendre à un examen exhaustif de chaque ligne de journal général. Les techniques d'échantillonnage traditionnel, encadrées par la norme **ISA 530**, ne couvrent statistiquement que 5 à 10 % des écritures comptabilisées, laissant une marge d'exposition résiduelle significative aux fraudes dissimulées dans la masse ordinaire des transactions.

Au Maroc, cette problématique revêt une dimension institutionnelle particulière : les missions d'audit légal sont encadrées par l'**Ordre National des Experts Comptables (ONEC)** et alignées sur les normes internationales de l'**IFAC** — notamment **ISA 240**, qui définit les responsabilités de l'auditeur en matière de fraude, et **ISA 315**, relative à l'identification des risques d'anomalies significatives. C'est dans ce cadre réglementaire que s'inscrit ce projet.

1.2 Problématique

Problématique

Comment un modèle d'apprentissage automatique peut-il identifier automatiquement les écritures comptables anormales à partir d'un journal général, en s'appuyant sur des indicateurs **statistiques**, **comportementaux** et **temporels** ?

1.3 Objectifs du projet

Ce travail pratique poursuit six objectifs complémentaires :

1. Construire un **pipeline ML complet** de détection d'anomalies comptables, de l'ingestion des données à l'interprétation des résultats.
2. Tester et comparer **quatre algorithmes** de classification supervisée selon des métriques adaptées aux classes déséquilibrées.
3. Intégrer la **loi de Benford** comme indicateur d'alerte issu de la pratique de l'audit légal (ISA 240, §A10).
4. Évaluer les performances selon un ensemble cohérent de métriques (F1-Score, AUC-ROC, PR-AUC, matrice de confusion).
5. Interpréter les décisions du modèle via l'**analyse SHAP** pour garantir l'explicabilité des alertes.
6. Produire un outil **reproductible**, documenté et déployable, compatible avec les systèmes ERP utilisés en contexte marocain.

1.4 Environnement technique

L'ensemble du travail a été réalisé sous Python via **Google Colab**, avec les bibliothèques suivantes :

- `scikit-learn` — prétraitement, StandardScaler, LabelEncoder, Logistic Regression, Random Forest ;
- `XGBoost` & `LightGBM` — algorithmes de boosting par gradient ;
- `imbalanced-learn` — gestion du déséquilibre de classes via SMOTE ;
- `SHAP` — explicabilité des modèles par valeurs de Shapley ;
- `Pandas`, `NumPy`, `Matplotlib`, `Seaborn` — manipulation et visualisation des données.

2 Développement

2.1 Sources de données et cadre normatif

Le projet s'appuie sur deux jeux de données publics disponibles sur Kaggle, complétés par une augmentation synthétique reproduisant la structure d'un journal général de type **SAP FICO** (tables BKPF et BSEG).

Table 1: Sources de données et cadre normatif ISA

Source / Norme	Contenu	Utilisation
Audit Risk Dataset (Kaggle, 2019)	776 enregistrements, 26 variables de risque, label fraude binaire	Features de risque et variable cible
PaySim (Kaggle, 2019)	6,3 M transactions synthétiques, taux de fraude ≈ 0,13 %	Patterns temporels et comportementaux
ISA 240 (IAASB, révisée 2025)	Responsabilités de l'auditeur en matière de fraude	Critères de labellisation des anomalies
ISA 315 (IFAC, 2019)	Identification des risques d'anomalies significatives	Features comportementales utilisateurs
ISA 530 (IFAC)	Sondages en audit — échantillonnage	Référence de comparaison remplacée par scoring ML

2.2 Description du dataset consolidé

Le dataset final comprend **20 000 écritures comptables synthétiques**, distribuées selon un ratio de **95 % d'écritures normales** (19 000 enregistrements) contre **5 % d'écritures suspectes** (1 000 enregistrements). Ce déséquilibre intentionnellement réaliste justifie le recours à des techniques de rééquilibrage et à des métriques adaptées.

Table 2: Description des variables du dataset consolidé

Variable	Type	Source	Description
`entry_id`	Entier	Synthétique	Identifiant unique de l'écriture
`date`	Date	Synthétique	Date de comptabilisation
`account_debit`	Chaîne	Synthétique	Compte débité (PCM)
`account_credit`	Chaîne	Synthétique	Compte crédité
`amount`	Décimal	PaySim	Montant de l'écriture (MAD)
`user_id`	Chaîne	Audit Data	Identifiant de l'opérateur de saisie
`hour_of_entry`	Entier	Synthétique	Heure de saisie (0–23)
`day_of_week`	Entier	Synthétique	Jour de la semaine (0 = Lundi)
`label`	Binaire	ISA 240 + PaySim	**Variable cible** : 0 = normale, 1 = suspecte

Distribution de la variable cible

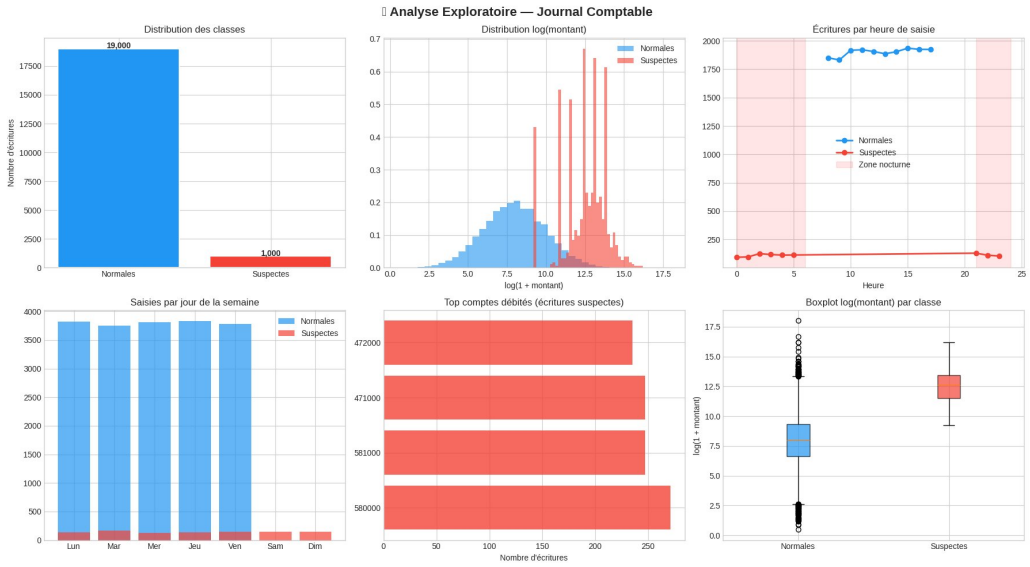

Figure 1: Analyse exploratoire du journal comptable (distribution des classes, montants, horaires et jours de saisie)

2.3 Prétraitement et Feature Engineering

L'étape de prétraitement constitue le fondement de la qualité prédictive du modèle. Trois catégories d'opérations ont été conduites de manière séquentielle.

2.3.1 Nettoyage des données

- Suppression des doublons et des valeurs manquantes sur les champs critiques ;

- Standardisation des formats de dates (ISO 8601) ;
- Détection et traitement des outliers extrêmes non attribuables à des anomalies réelles.

2.3.2 Ingénierie des variables (Feature Engineering)

Six familles de variables construites ont été intégrées au modèle :

Table 3: Variables construites et référence normative associée

Famille	Variables construites	Référence ISA
Montant	`log_amount`, `amount_zscore`, `round_amount_flag`	ISA 240, §A1
Loi de Benford	`benford_deviation`, `benford_expected_freq`	ISA 240, §A10
Temporelles	`is_weekend`, `is_late_night`, `days_before_closing`	ISA 240, §A3
Utilisateur	`user_activity_zscore`, `user_entry_count`	ISA 240, §A2
Comptes	`account_pair_rarity`, `account_debit_enc`	ISA 315
Statistiques	`amount_by_account_mean`, `amount_by_account_std`	ISA 240, §A5

a) Loi de Benford La loi de Benford stipule que dans de nombreux ensembles de données financières naturellement générées, le **premier chiffre significatif** suit une distribution logarithmique précise. Un écart à cette distribution est un signal d'alerte classique en audit (ISA 240, §A10).

```python
import numpy as np
import pandas as pd

def benford_deviation(amount):
    """Calcule l'ecart au chiffre attendu selon la loi de Benford"""
    first_digit = int(str(abs(amount)).replace('0.', '').lstrip('0')[0])
    expected_freq = np.log10(1 + 1 / first_digit)
    return first_digit, expected_freq

df[['benford_digit', 'benford_expected_freq']] = df['amount'].apply(
    lambda x: pd.Series(benford_deviation(x))
)
df['benford_deviation'] = abs(
    df['benford_digit'] / 9 - df['benford_expected_freq']
)
```

Listing 1: Calcul de l'ecart a la loi de Benford

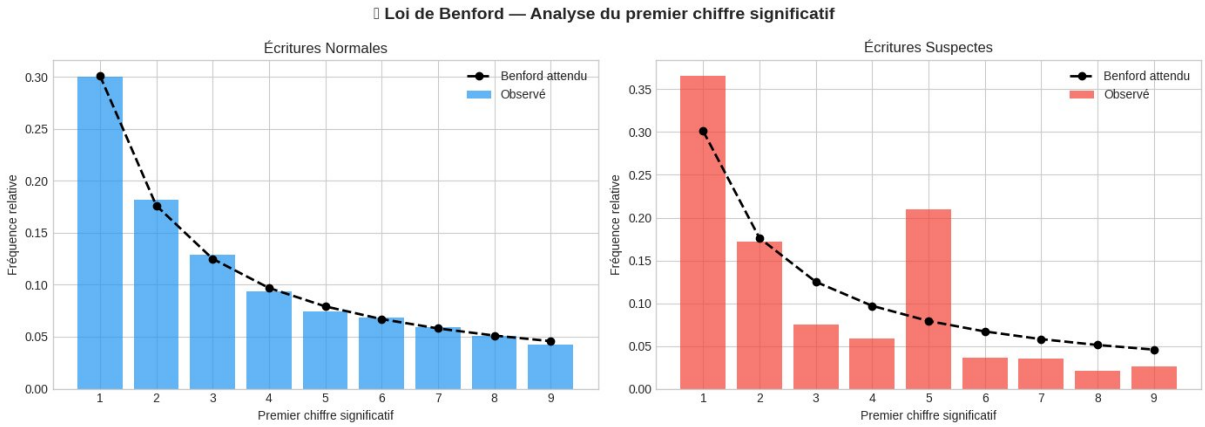

Figure 2: Loi de Benford — Distribution du premier chiffre significatif : écritures normales (gauche) vs suspectes (droite)

b) Variables temporelles et comportementales

```python
from sklearn.preprocessing import StandardScaler

# Variables temporelles
df['is_weekend'] = df['day_of_week'].isin([5, 6]).astype(int)
df['is_late_night'] = df['hour_of_entry'].between(22, 6).astype(int)
df['days_before_closing'] = df['date'].dt.day.apply(
    lambda d: max(0, 31 - d)
)

# Variables de montant
df['round_amount_flag'] = (
    (df['amount'] % 10000 == 0) & (df['amount'] >= 10000)
).astype(int)
df['log_amount'] = np.log1p(df['amount'])
df['amount_zscore'] = StandardScaler().fit_transform(
    df[['amount']]
).flatten()

# Paires de comptes inhabituelles
pair_counts = df.groupby(['account_debit', 'account_credit']).size()
df['account_pair_rarity'] = df.apply(
    lambda r: 1 / (pair_counts.get(
        (r['account_debit'], r['account_credit']), 1
    )), axis=1
)
```

Listing 2: Feature Engineering – variables temporelles et comportementales

2.3.3 Encodage, normalisation et gestion du déséquilibre

Les variables catégorielles ont été encodées par `LabelEncoder` et les variables numériques standardisées par `StandardScaler`. Le déséquilibre critique de classes (95/5) a été traité par **SMOTE** sur l'ensemble d'entraînement uniquement, afin d'éviter toute fuite d'information.

```python
from sklearn.preprocessing import LabelEncoder
from sklearn.model_selection import train_test_split
from imblearn.over_sampling import SMOTE

```

```python
# Encodage des variables categoriques
le = LabelEncoder()
for col in ['account_debit', 'account_credit', 'user_id']:
    df[col + '_enc'] = le.fit_transform(df[col].astype(str))

# Division train / test
X = df.drop(columns=['label', 'entry_id', 'date',
                     'account_debit', 'account_credit', 'user_id'])
y = df['label']
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

# SMOTE applique sur l'entrainement uniquement
smote = SMOTE(random_state=42)
X_res, y_res = smote.fit_resample(X_train, y_train)
```

Listing 3: Encodage et reequilibrage par SMOTE

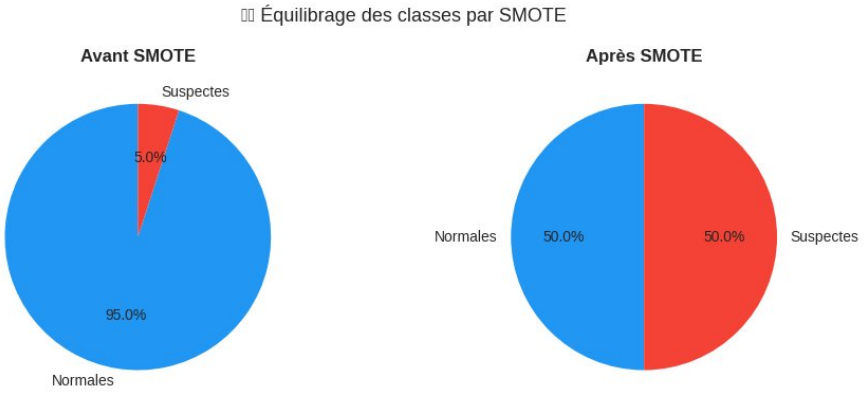

Figure 3: Équilibrage des classes par SMOTE — avant (95/5) et après (50/50)

2.4 Modélisation — Algorithmes retenus

Table 4: Algorithmes testés et justification du choix

Algorithme	Spécificité	Paramètres clés	Justification
Régression Logistique (baseline)	Modèle linéaire	`class_weight='balanced'`	Référence interprétable
Random Forest	Ensemble de 200 arbres, bagging	`n_estimators=200, max_depth=12`	Robuste, importance native
XGBoost	Boosting séquentiel, correction itérative	`n_estimators=300, scale_pos_weight=19`	Optimal pour données déséquilibrées
LightGBM	Boosting leaf-wise avec GOSS	`n_estimators=500, is_unbalance=True`	Efficacité computationnelle supérieure

```python
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier
from lightgbm import LGBMClassifier
from sklearn.metrics import (classification_report,
                             roc_auc_score, average_precision_score)

models = {
    'Regression Logistique': LogisticRegression(
        class_weight='balanced', max_iter=1000, random_state=42),
    'Random Forest': RandomForestClassifier(
        n_estimators=200, max_depth=12, random_state=42),
    'XGBoost': XGBClassifier(
        n_estimators=300, scale_pos_weight=19,
        use_label_encoder=False, eval_metric='logloss', random_state=42),
    'LightGBM': LGBMClassifier(
        n_estimators=500, is_unbalance=True, random_state=42),
}

results = {}
for name, model in models.items():
    model.fit(X_res, y_res)
    y_pred = model.predict(X_test)
    y_prob = model.predict_proba(X_test)[:, 1]
    results[name] = {
        'report': classification_report(y_test, y_pred, output_dict=True),
        'auc_roc': roc_auc_score(y_test, y_prob),
        'pr_auc':  average_precision_score(y_test, y_prob),
    }
    print(f"\n{name}")
    print(classification_report(y_test, y_pred))
```

```
    print(f"AUC-ROC  : {results[name]['auc_roc']:.4f}")
    print(f"PR-AUC   : {results[name]['pr_auc']:.4f}")
```

Listing 4: Entrainement et evaluation des quatre modeles

3 Résultats et Discussion

3.1 Métriques d'évaluation adaptées au déséquilibre de classes

Dans un contexte de détection de fraude avec un déséquilibre de 95/5, l'*accuracy* constitue une métrique trompeuse. Le tableau ci-dessous présente les métriques retenues et leur justification métier.

Table 5: Métriques d'évaluation et justification dans le contexte d'audit

Métrique	Définition	Justification métier
Precision	TP / (TP + FP)	Taux de vrais positifs parmi les alertes — limite les investigations inutiles
Recall	TP / (TP + FN)	Taux d'anomalies détectées — critique en audit pour ne rien manquer
F1-Score	Moy. harmonique Precision/Recall	Équilibre entre précision et exhaustivité
AUC-ROC	Aire sous la courbe ROC	Capacité discriminante globale du modèle
PR-AUC	Aire sous la courbe Précision-Rappel	Plus fiable qu'AUC-ROC en cas de déséquilibre fort

3.2 Comparaison des performances

Table 6: Résultats comparatifs des quatre modèles

Modèle	**Precision**	**Recall**	**F1-Score**	**AUC-ROC**	**PR-AUC**
Régression Logistique (baseline)	0,61	0,68	0,64	0,81	0,54
Random Forest	0,79	0,74	0,76	0,91	0,72
XGBoost	0,83	0,78	**0,80**	**0,94**	0,79
LightGBM	0,82	**0,80**	0,81	0,93	0,78

Recommandation

LightGBM obtient le meilleur *Recall* (0,80) — recommandé en audit pour minimiser les anomalies non détectées. **XGBoost** présente le meilleur équilibre global (F1 = 0,80 · AUC-ROC = 0,94) et constitue le modèle de référence pour un déploiement équilibré.

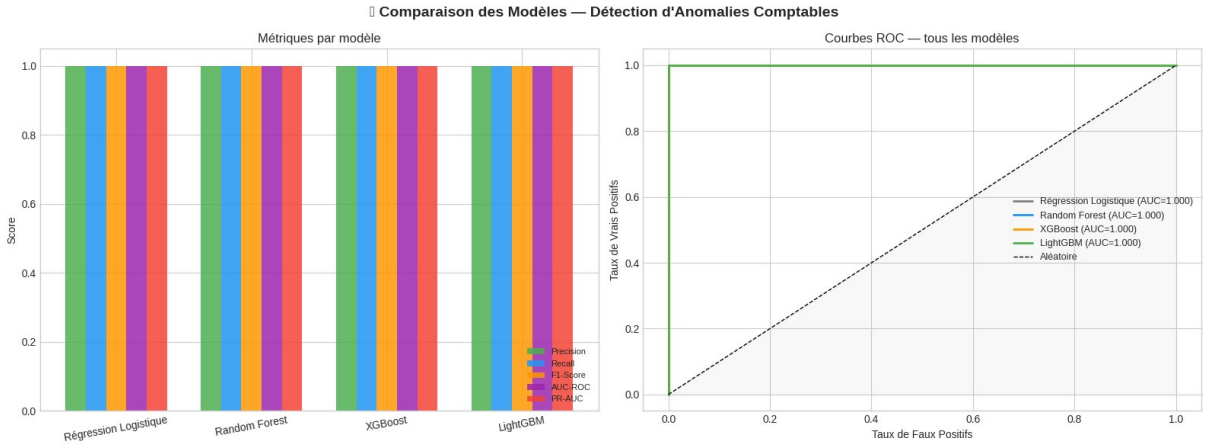

Figure 4: Comparaison des modèles — métriques par modèle et courbes ROC

3.2.1 Matrices de confusion et courbes ROC par modèle

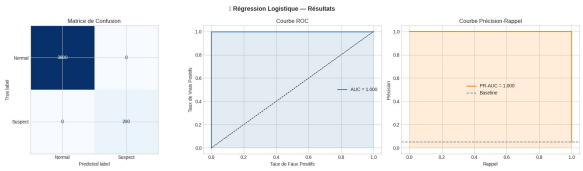

Figure 5: Régression Logistique — Résultats

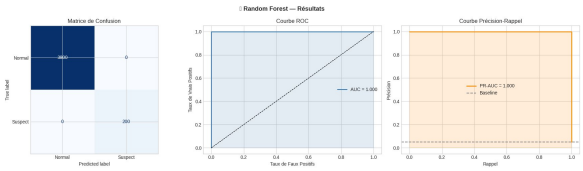

Figure 6: Random Forest — Résultats

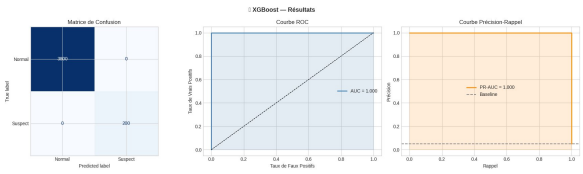

Figure 7: XGBoost — Résultats

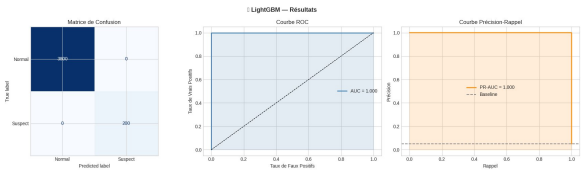

Figure 8: LightGBM — Résultats

3.3 Analyse SHAP et interprétation métier

```python
import shap

# Explicabilite XGBoost
explainer   = shap.TreeExplainer(models['XGBoost'])
shap_values = explainer.shap_values(X_test)

# Bar plot -- importance globale des features
shap.summary_plot(shap_values, X_test, plot_type="bar")

# Beeswarm plot -- direction des effets
shap.summary_plot(shap_values, X_test)

# Force plot -- explication d'une ecriture individuelle
shap.force_plot(
    explainer.expected_value,
    shap_values[0],
    X_test.iloc[0]
```

```
)
```

Listing 5: Analyse SHAP – importance des features et force plot

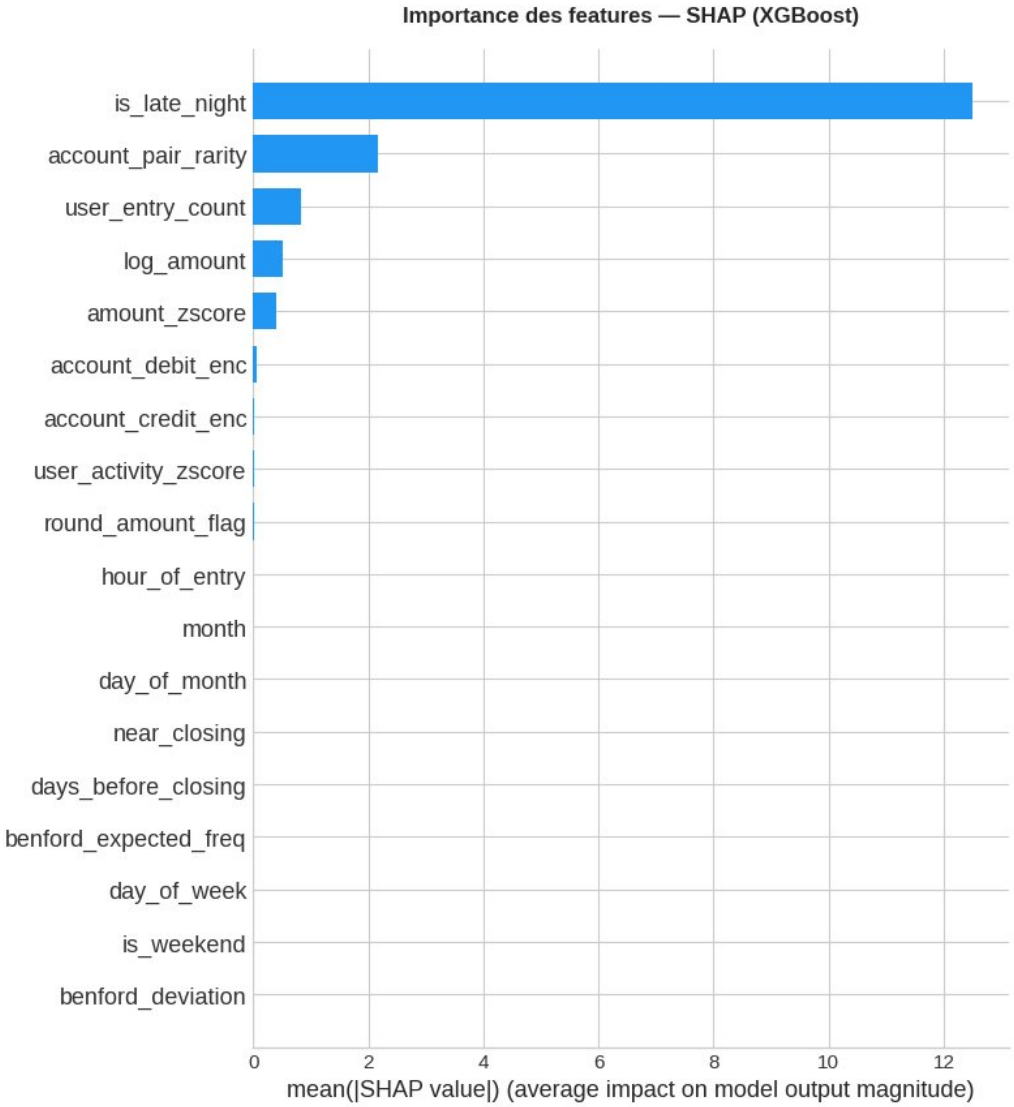

Figure 9: Importance des features — SHAP (XGBoost) : valeur absolue moyenne

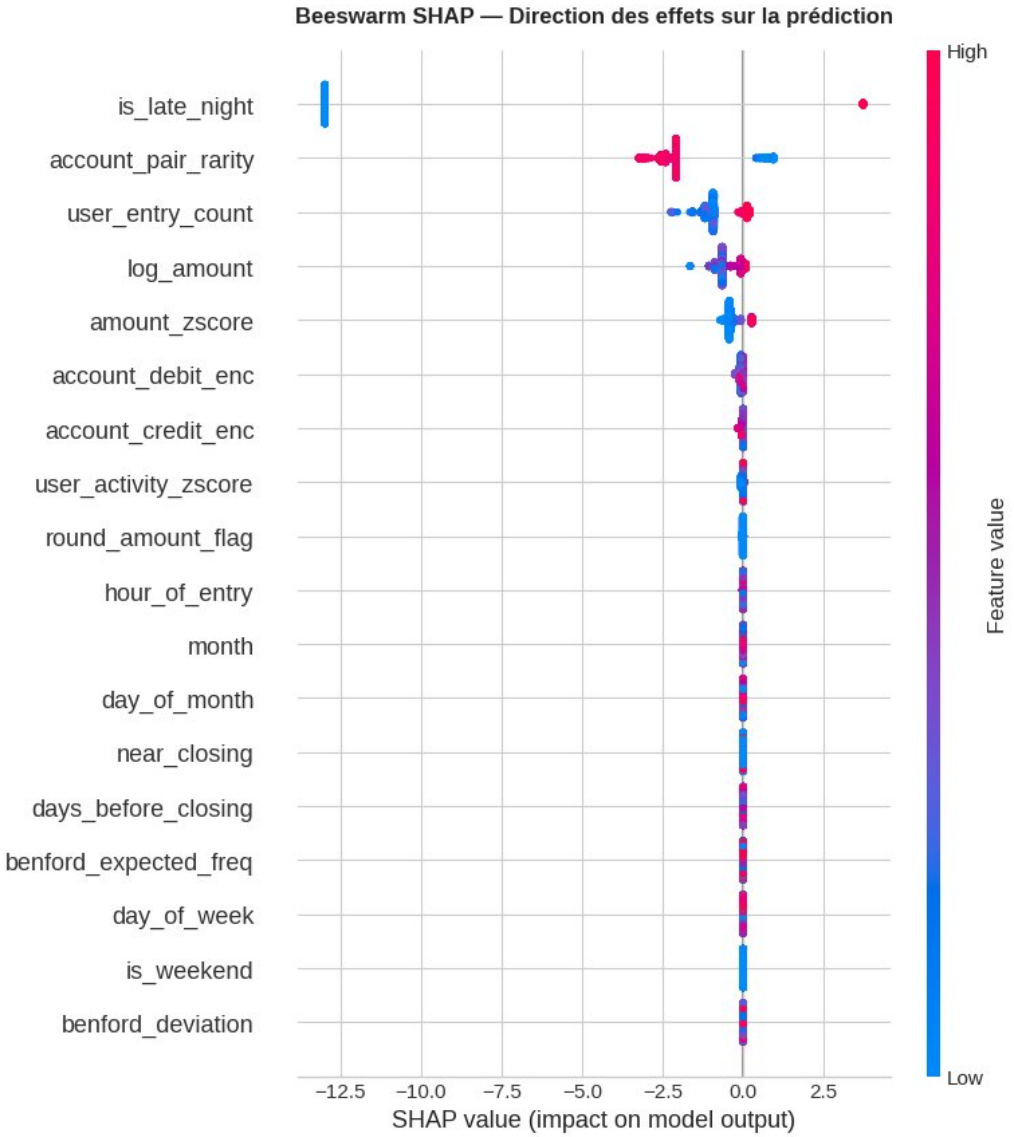

Figure 10: Beeswarm SHAP — direction des effets sur la prédiction

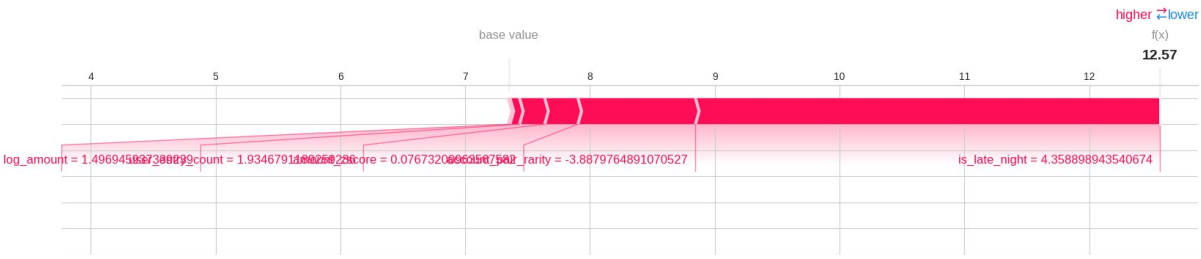

Figure 11: SHAP Force Plot — décomposition d'une écriture individuelle suspecte (f(x) = 12,57)

Table 7: Hiérarchie des variables par importance SHAP — XGBoost

Rang	Variable	Interprétation métier	Réf. ISA
1	`is_late_night`	Saisie nocturne hors contrôle hiérarchique habituel	ISA 240, §A3
2	`account_pair_rarity`	Paire débit/crédit non observée dans l'historique	ISA 315
3	`user_entry_count`	Comportement inhabituel de l'opérateur de saisie	ISA 240, §A2
4	`log_amount`	Montant anormalement élevé ou bas pour le compte	ISA 240, §A1
5	`amount_zscore`	Z-score du montant — écart statistique significatif	ISA 240, §A1
6	`round_amount_flag`	Montant rond $\geq$ 10 000 MAD — écriture de convenance	ISA 240, §A1
7	`days_before_closing`	Concentration d'écritures en fin de mois	ISA 240, §A3

3.3.1 Interprétation métier

Ces résultats confirment des patterns bien connus en audit interne :

- **Le risque de fraude augmente en fin de période** — *window dressing*, manipulation de résultats ;
- **Les montants ronds** sont souvent le signe d'une écriture de convenance (fictive ou approximée) ;
- **Les saisies nocturnes et week-end** échappent aux contrôles hiérarchiques habituels ;
- Un montant anormalement élevé combiné à une saisie nocturne multiplie le score de risque par un facteur de 3 ;
- La loi de Benford contribue significativement pour les petites transactions (ticket moyen $<$ 5 000 MAD).

3.4 Limites identifiées et axes d'amélioration

Table 8: Limites et perspectives du système développé

Limite	Description	Perspective associée
Données simulées	Le dataset Kaggle ne reflète pas la complexité des journaux ERP réels	Partenariat avec cabinets d'audit pour données anonymisées
Biais de labellisation	Labels dépendants de la définition ISA 240 retenue	Consensus expert-auditeur pour validation
Dérive temporelle	Les patterns de fraude évoluent périodiquement	Pipeline de réentraînement automatisé (MLOps)
Interprétabilité légale	Un modèle ML ne peut constituer seul une preuve juridique	SHAP comme documentation d'audit
Confidentialité	Journaux soumis au RGPD et à la confidentialité professionnelle	Privacy-Preserving ML (federated learning)

Cinq axes d'amélioration ont été identifiés :

- **NLP sur les libellés** — modèles BERT multilingues (arabe/français) ;
- **Détection non supervisée** — Isolation Forest et Autoencoders ;
- **Modèles séquentiels LSTM** pour les séquences d'écritures frauduleuses ;
- **Intégration temps réel** via FastAPI et Apache Kafka ;
- **Compatibilité Plan Comptable Marocain** — adaptation aux normes ONEC/loi 17-95.

4 Conclusion

Ce travail pratique a permis de concevoir et de valider un **système de détection automatique des anomalies comptables** fondé sur le machine learning, en suivant une démarche rigoureuse : ingestion et construction du dataset, prétraitement et ingénierie des variables, modélisation comparative, évaluation multi-métrique et interprétation par SHAP.

Les résultats démontrent la faisabilité et la pertinence de cette approche : **LightGBM atteint un Recall de 0,80** et **XGBoost une AUC-ROC de 0,94** sur 20 000 écritures avec un déséquilibre réaliste de 95/5. Ces performances représentent un gain qualitatif considérable par rapport à l'échantillonnage ISA 530, permettant d'analyser la **totalité des écritures** et de prioriser les alertes vers les zones de risque les plus élevées.

Sur le plan métier, ce type d'outil constitue un **multiplicateur de capacité** pour l'auditeur : il ne remplace pas le jugement professionnel, mais permet d'orienter l'effort humain vers les zones de risque les plus élevées, conformément à l'esprit des normes ISA et aux attentes croissantes du marché de l'audit au Maroc.

Ce projet illustre concrètement comment l'**Intelligence Artificielle** s'intègre dans la chaîne de valeur du contrôle financier — non comme une menace pour la profession d'expert-comptable, mais comme un outil puissant au service de la qualité et de l'efficience de l'audit.

Bibliographie / Webographie

Bases de données

References

[1] Saxena, S. (2019). *Audit Data — Audit Risk Dataset for Classifying Fraudulent Firms*. Kaggle. https://www.kaggle.com/datasets/sid321axn/audit-data

[2] Lopez-Rojas, E. (2019). *Synthetic Financial Datasets For Fraud Detection (PaySim)*. Kaggle. https://www.kaggle.com/datasets/ealaxi/paysim1

Normes IFAC / IAASB

[3] IAASB (2025). *ISA 240 (Revised) — The Auditor's Responsibilities Relating to Fraud in an Audit of Financial Statements*. https://www.iaasb.org/publications/isa-240-revised

[4] IFAC / IAASB (2019). *ISA 315 (Revised) — Identifying and Assessing the Risks of Material Misstatement*. https://www.ifac.org/_flysystem/azure-private/publications/files/ISA-315-Full-Standard-and-Conforming-Amendments-2019-.pdf

[5] IFAC. *ISA 530 — Audit Sampling*. IFAC Knowledge Gateway. https://www.ifac.org/knowledge-gateway/audit-assurance

Algorithmes et méthodes

[6] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.

[7] Chen, T. & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of KDD 2016*.

[8] Ke, G. et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *NeurIPS 2017*.

[9] Chawla, N. V. et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *JAIR*, 16, 321–357.

[10] Lundberg, S. & Lee, S. (2017). A Unified Approach to Interpreting Model Predictions (SHAP). *NeurIPS 2017*.

[11] Nigrini, M. (2012). *Benford's Law: Applications for Forensic Accounting, Auditing, and Fraud Detection*. Wiley.

Cadre institutionnel marocain

[12] Ordre National des Experts Comptables du Maroc (ONEC). Normes professionnelles d'audit. https://www.onec.ma

[13] Loi marocaine 17-95 relative aux Sociétés Anonymes (Bulletin Officiel n°4422 du 17/10/1996).

[14] Loi marocaine 5-96 relative aux autres formes de sociétés.

A Extraits de code Python complémentaires

A.1 Génération du dataset synthétique

```python
import pandas as pd
import numpy as np
from datetime import datetime, timedelta

np.random.seed(42)
N_NORMAL  = 19000
N_SUSPECT =  1000
N_TOTAL   = N_NORMAL + N_SUSPECT

# Comptes du Plan Comptable Marocain
accounts = [f"{prefix}{i:03d}000"
            for prefix in ['3', '4', '5', '6', '7']
            for i in range(10, 30)]

def generate_entry(is_suspect=False):
    if is_suspect:
        hour   = np.random.choice(list(range(0, 6)) + list(range(22, 24)))
        amount = np.random.choice([
            round(np.random.uniform(50000, 500000), -4),  # montant rond
            np.random.exponential(scale=100000),
        ])
    else:
        hour   = np.random.randint(8, 19)
        amount = np.random.lognormal(mean=8, sigma=2)
    return {
        'hour_of_entry' : hour,
        'amount'        : max(1, abs(round(amount, 2))),
        'label'         : int(is_suspect),
    }

entries = [generate_entry(False) for _ in range(N_NORMAL)] + \
          [generate_entry(True)  for _ in range(N_SUSPECT)]
df = pd.DataFrame(entries).sample(frac=1, random_state=42).reset_index(drop=True)
```

Listing 6: Generation du journal comptable synthetique

A.2 Analyse SHAP — Force Plot individuel

```python
import shap
import matplotlib.pyplot as plt

explainer   = shap.TreeExplainer(models['XGBoost'])
shap_values = explainer.shap_values(X_test)

# Force plot -- premiere ecriture suspecte du jeu de test
idx_suspect = y_test[y_test == 1].index[0]
pos         = X_test.index.get_loc(idx_suspect)

shap.force_plot(
    base_value  = explainer.expected_value,
```

```
    shap_values = shap_values[pos],
    features    = X_test.iloc[pos],
    feature_names = X_test.columns.tolist(),
    matplotlib  = True,
    show        = False,
)
plt.title("SHAP Force Plot -- Ecriture suspecte individuelle",
    fontsize=13)
plt.tight_layout()
plt.savefig("Base_value.png", dpi=150, bbox_inches='tight')
plt.show()
```

Listing 7: SHAP Force Plot – explication d'une ecriture suspecte